

# **LAPORAN TUGAS**

## **LAB: NEURAL INFORMATION RETRIEVAL**



Mata Kuliah: Temu Kembali Informasi / Sistem Temu Kembali Informasi

Dosen Pengampu: Zico Pratama Putra

Kelompok 1:

- Rizqia Fauziah Rachma – 14250002
- Tungkot Siregar – 14250003
- Intan Saesaria – 14250004

Program Studi Ilmu Komputer (S2)

Fakultas Teknologi Informasi

Universitas Nusa Mandiri

Jakarta

2026

## 1. PENDAHULUAN DAN TUJUAN

### 1.1 Latar Belakang

Sistem pencarian informasi tradisional berbasis pencocokan kata kunci (*lexical matching*) seperti BM25 sering kali gagal menangkap maksud atau makna kontekstual dari sebuah *query*. Ketika pengguna memasukkan pertanyaan yang bersifat natural, sistem tradisional hanya mencari kecocokan token kata tanpa memahami sinonim atau hubungan semantik antar kalimat.

Untuk mengatasi kelemahan tersebut, proyek ini mengimplementasikan sistem pencarian dua tahap (*Two-stage Retrieval*). Tahap pertama (Retriever) berfungsi menyaring kandidat dokumen secara cepat dari basis data, kemudian tahap kedua (Re-ranker) menggunakan model Transformer berbasis pembelajaran mendalam (*Deep Learning*) untuk mengurutkan ulang dokumen berdasarkan kedekatan semantik yang lebih akurat.

### 1.2 Tujuan

- Mengimplementasikan strategi agregasi tingkat lanjut (*Advanced Aggregation*) untuk membersihkan data multi-penilai (*multi-annotator*) dari dataset FiRA.
- Membangun dan menguji performa model **BERT Cross-Encoder** (cross-encoder/ms-marco-MiniLM-L-6-v2) untuk melakukan pengurutan ulang (*re-ranking*) dokumen secara semantik.
- Mengintegrasikan komponen **Extractive Question Answering** menggunakan model deepset/roberta-base-squad2 untuk menyajikan jawaban instan langsung dari dokumen terbaik.
- Mengevaluasi keandalan sistem temu kembali informasi menggunakan metrik standar: *Precision@10* (P@10), *Mean Reciprocal Rank* (MRR@10), dan *Normalized Discounted Cumulative Gain* (NDCG@10).

## 2. METODOLOGI AGREGASI JUDGEMENT (PART 1)

### 2.1 Permasalahan Data Mentah

Dataset FiRA (*fira\_raw\_judgements.tsv*) mengandung penilaian multi-annotator, di mana satu pasang *query-document* dinilai oleh beberapa manusia yang berbeda. Hal ini menimbulkan masalah subjektivitas tinggi, inkonsistensi, dan potensi adanya penilai yang kurang teliti (*low-confidence* atau *noisy annotations*).

## 2.2 Strategi Agregasi Lanjutan (Advanced Weighted Aggregation)

```
... Loaded 237 raw judgements
Columns: ['query_id', 'doc_id', 'judgement', 'confidence', 'annotator_id', 'duration_ms']
  query_id doc_id judgement confidence annotator_id duration_ms
0         1   d1_1         3        0.85        User_5       30289
1         1   d1_1         3        0.94        User_0       83482
2         1   d1_1         3        0.92        User_4       16165
3         1   d1_2         2        0.81        User_0       38062
4         1   d1_2         1        0.92        User_5       12851
Aggregated into 79 unique query-doc pairs
Qrels saved to data/fira_aggregated.qrels
```

Gambar 1: Log eksekusi pembersihan dan agregasi data penilai FiRA ke format TREC qrels.

Kelompok kami mengimplementasikan strategi Weighted Advanced Aggregation pada berkas judgement\_aggregation.py dengan alur sebagai berikut:

1. **Kalkulasi Kredibilitas Annotator:** Menghitung nilai rata-rata penilaian (*mean score*) untuk setiap pasang dokumen, kemudian menghitung rata-rata deviasi (penyimpangan) setiap individu annotator terhadap rata-rata tersebut. Annotator yang memiliki deviasi tinggi diberikan bobot penaltis yang lebih rendah dengan rumus:
2. **Weighted Voting:** Skor akhir dikonstruksikan menggunakan rata-rata terbobot (*weighted average*) yang mengalikan nilai penilaian (*judgement*) dengan kolom tingkat kepercayaan penilai (*confidence*) dan bobot kredibilitas annotator yang telah dihitung.
3. **Penyimpanan Standar:** Nilai kontinu hasil rata-rata dibulatkan ke integer terdekat (skala 0-3) dan diekspor ke dalam format standar TREC qrels (fira\_aggregated.qrels) sebagai landasan *ground truth* evaluasi.

## 3. ARSITEKTUR MODEL BERT CROSS-ENCODER & QA (PART 2 & 3)

### 3.1 BERT Cross-Encoder Re-Ranking

Model yang digunakan adalah cross-encoder/ms-marco-MiniLM-L-6-v2. Berbeda dengan Bi-Encoder yang memproses *query* dan *document* secara terpisah, arsitektur Cross-Encoder memasukkan teks *query* dan *passage* secara simultan (sekaligus) ke dalam model BERT dengan *attention mask* penuh. Hal ini memungkinkan terjadinya *full-attention* lintas kata antar kedua teks, sehingga prediksi skor klasifikasi relevansi biner atau skor regresi logits menjadi jauh lebih tebal dan akurat.

### 3.2 Fine-Tuning/Training Loop

Fungsi train() pada bert\_cross\_encoder.py diimplementasikan menggunakan *Classification Loss* berbasis *Cross-Entropy Loss* (atau *BCEWithLogitsLoss* untuk single logit output). Optimasi dilakukan menggunakan AdamW dengan *linear learning rate schedule* dan tahapan *warmup* sebesar 10% dari total langkah pelatihan.

### 3.3 Extractive Question Answering

Setelah dokumen diurutkan, dokumen pada peringkat teratas (Top-1) diteruskan ke modul *Extractive QA* menggunakan model deepset/roberta-base-squad2. Guna menghindari

pembatasan registrasi *task pipeline* bawaan pada beberapa lingkungan repositori, ekstraksi dilakukan secara manual dengan memetakan nilai *start logits* dan *end logits* tertinggi untuk memotong token jawaban dari dokumen secara presisi.

## 4. HASIL EKSPERIMEN DAN ANALISIS

### 4.1 Log Running dan Output Ekstraksi Jawaban

Pada skenario pengujian dengan *query*: "How to make a good cappuccino?", model Cross-Encoder berhasil mengidentifikasi dokumen yang paling relevan di peringkat pertama. Selanjutnya, komponen Extractive QA berhasil memotong paragraf tersebut dan menyajikan jawaban yang bersih:


```
*** Loading weights: 100% 199/199 [00:00<00:00, 1181.88it/s]

=== Extractive QA Result ===
{'answer': 'espresso, steamed milk, and foam'}
```

Gambar 2: Hasil re-ranking dokumen cappuccino menggunakan BERT Cross-Encoder dan ekstraksi jawaban teks oleh RoBERTa.

### 4.2 Hasil Evaluasi Metrik

Proses evaluasi kuantitatif terhadap sistem temu kembali dilakukan pada batas peringkat  $K=10$ . Hasil running pada berkas notebook menunjukkan angka sebagai berikut:



Gambar 3: Grafik Batang Performa Hasil Re-ranking Model BERT Cross-Encoder pada Batas Peringkat  $K=10$  (Metrik  $P@10$ ,  $MRR@10$ , dan  $NDCG@10$ ).

Berdasarkan grafik pada **Gambar 4.1**, dapat dilihat bahwa sistem berhasil mencapai nilai optimal pada metrik berbasis peringkat dengan skor  $MRR@10 = 1.0000$  dan  $NDCG@10 = 1.0000$ . Hal ini membuktikan efektivitas pemeringkatan semantik Cross-Encoder dalam menempatkan dokumen paling relevan di urutan pertama, didukung oleh data hasil agregasi yang bersih.

### 4.3 Analisis Performa

- Nilai **MRR@10 yang menyentuh 1.0000** membuktikan ketajaman arsitektur Cross-Encoder dalam melakukan pembobotan semantik. Dokumen emas (*gold document*) langsung diletakkan di urutan paling atas tanpa memaksa pengguna melakukan *scrolling*.
- Nilai **NDCG@10 sebesar 1.0000** menegaskan bahwa model sangat peka terhadap tingkatan relevansi data. Dokumen berkategori "Sangat Relevan" (skor 3) terbukti berada di atas dokumen berkategori "Cukup Relevan" (skor 2), dan dokumen tidak relevan tertekan ke bawah.
- Nilai **P@10 sebesar 0.2000 (20%)** bukan mengindikasikan kegagalan model, melainkan keterbatasan jumlah dokumen relevan di dalam repositori data uji (hanya tersedia 2 dokumen relevan). Karena rumusnya dibagi dengan  $K=10$ , maka nilai  $2/10 = 0.2000$  menunjukkan bahwa model memiliki tingkat *Recall* sebesar 100% karena berhasil menemukan seluruh jarum di dalam tumpukan jerami.

## 5. KESIMPULAN DAN TANTANGAN

### 5.1 Kesimpulan

Penerapan arsitektur *Two-stage Retrieval* menggunakan kombinasi BERT Cross-Encoder dan Extractive QA terbukti menjadi solusi yang sangat solid untuk sistem pencarian modern. Strategi pembersihan data penilai (*FiRA Aggregation*) terbukti krusial dalam menyajikan data latih yang bersih, yang pada gilirannya mendongkrak akurasi pemeringkatan semantik hingga mencapai nilai metrik ideal ( $MRR \& NDCG = 1.0000$ ).

### 5.2 Tantangan dan Solusi

Tantangan teknis utama dalam proyek ini adalah penanganan *output dimension mismatch* pada logits Cross-Encoder serta isu eror registrasi *task question-answering* pada fungsi pipeline bawaan pustaka Transformers di lingkungan tertentu. Masalah ini berhasil dimitigasi secara tuntas dengan:

1. Menambahkan fungsi pengkondisian dimensi logit (`outputs.logits.shape[1] == 1`) untuk mengalihkan fungsi klasifikasi biner ganda ke fungsi aktivasi `torch.sigmoid` kontinu.
2. Membangun mekanisme inferensi token logits manual menggunakan *argmax* koordinat indeks kata awal dan akhir dari model RoBERTa secara langsung.

## 6. PEMBAGIAN TUGAS KELOMPOK

- ✓ Rizqia Fauziah Rachma (14250002): Fokus pada Part 1 (FiRA Judgement Aggregation).
- ✓ Tungkot Siregar (14250003): Fokus pada Part 2 (BERT Cross-Encoder Re-Ranking).
- ✓ Intan Saesaria (14250004): Fokus pada Part 3 (Extractive QA) & Evaluasi Akhir.